


Inteligencia Artificial Aplicada

Diagnóstico de Fallas en Rodamientos con el Dataset HUST Bearing

Integrantes:

Adolfo Benítez
Sergio Frutos
Arturo Arrúa



Objetivos

01

¿Como diagnosticamos las fallas en los rodamientos?

02

Procesamiento de nuestros datos y características extraídas



¿Que buscamos?

Este proyecto está enfocado en el diagnóstico de fallas en rodamientos utilizando un dataset práctico conocido como HUST Bearing.

Datos específicos de rodamientos:

- **Diámetro interno:** 35 mm
- **Diámetro externo:** 72 mm
- **Diámetro de bola:** 11 mm
- **Número de bolas:** 9







Visualización de Datos

Se grafican los datos de vibración para todas las condiciones analizadas.



Se utilizan cinco tipos de falla del dataset:

B700, I700, IB700, IO700 y N700

Donde la primera letra hace referencia al tipo de falla, el primer número al tipo de ruleman, y los últimos dos dígitos a la carga.





Visualización de Datos



Como ejemplo se muestran los datos de las condiciones de falla de bola y normal

Reducción de picos




Para esto se utilizó un filtro de desviación estándar.



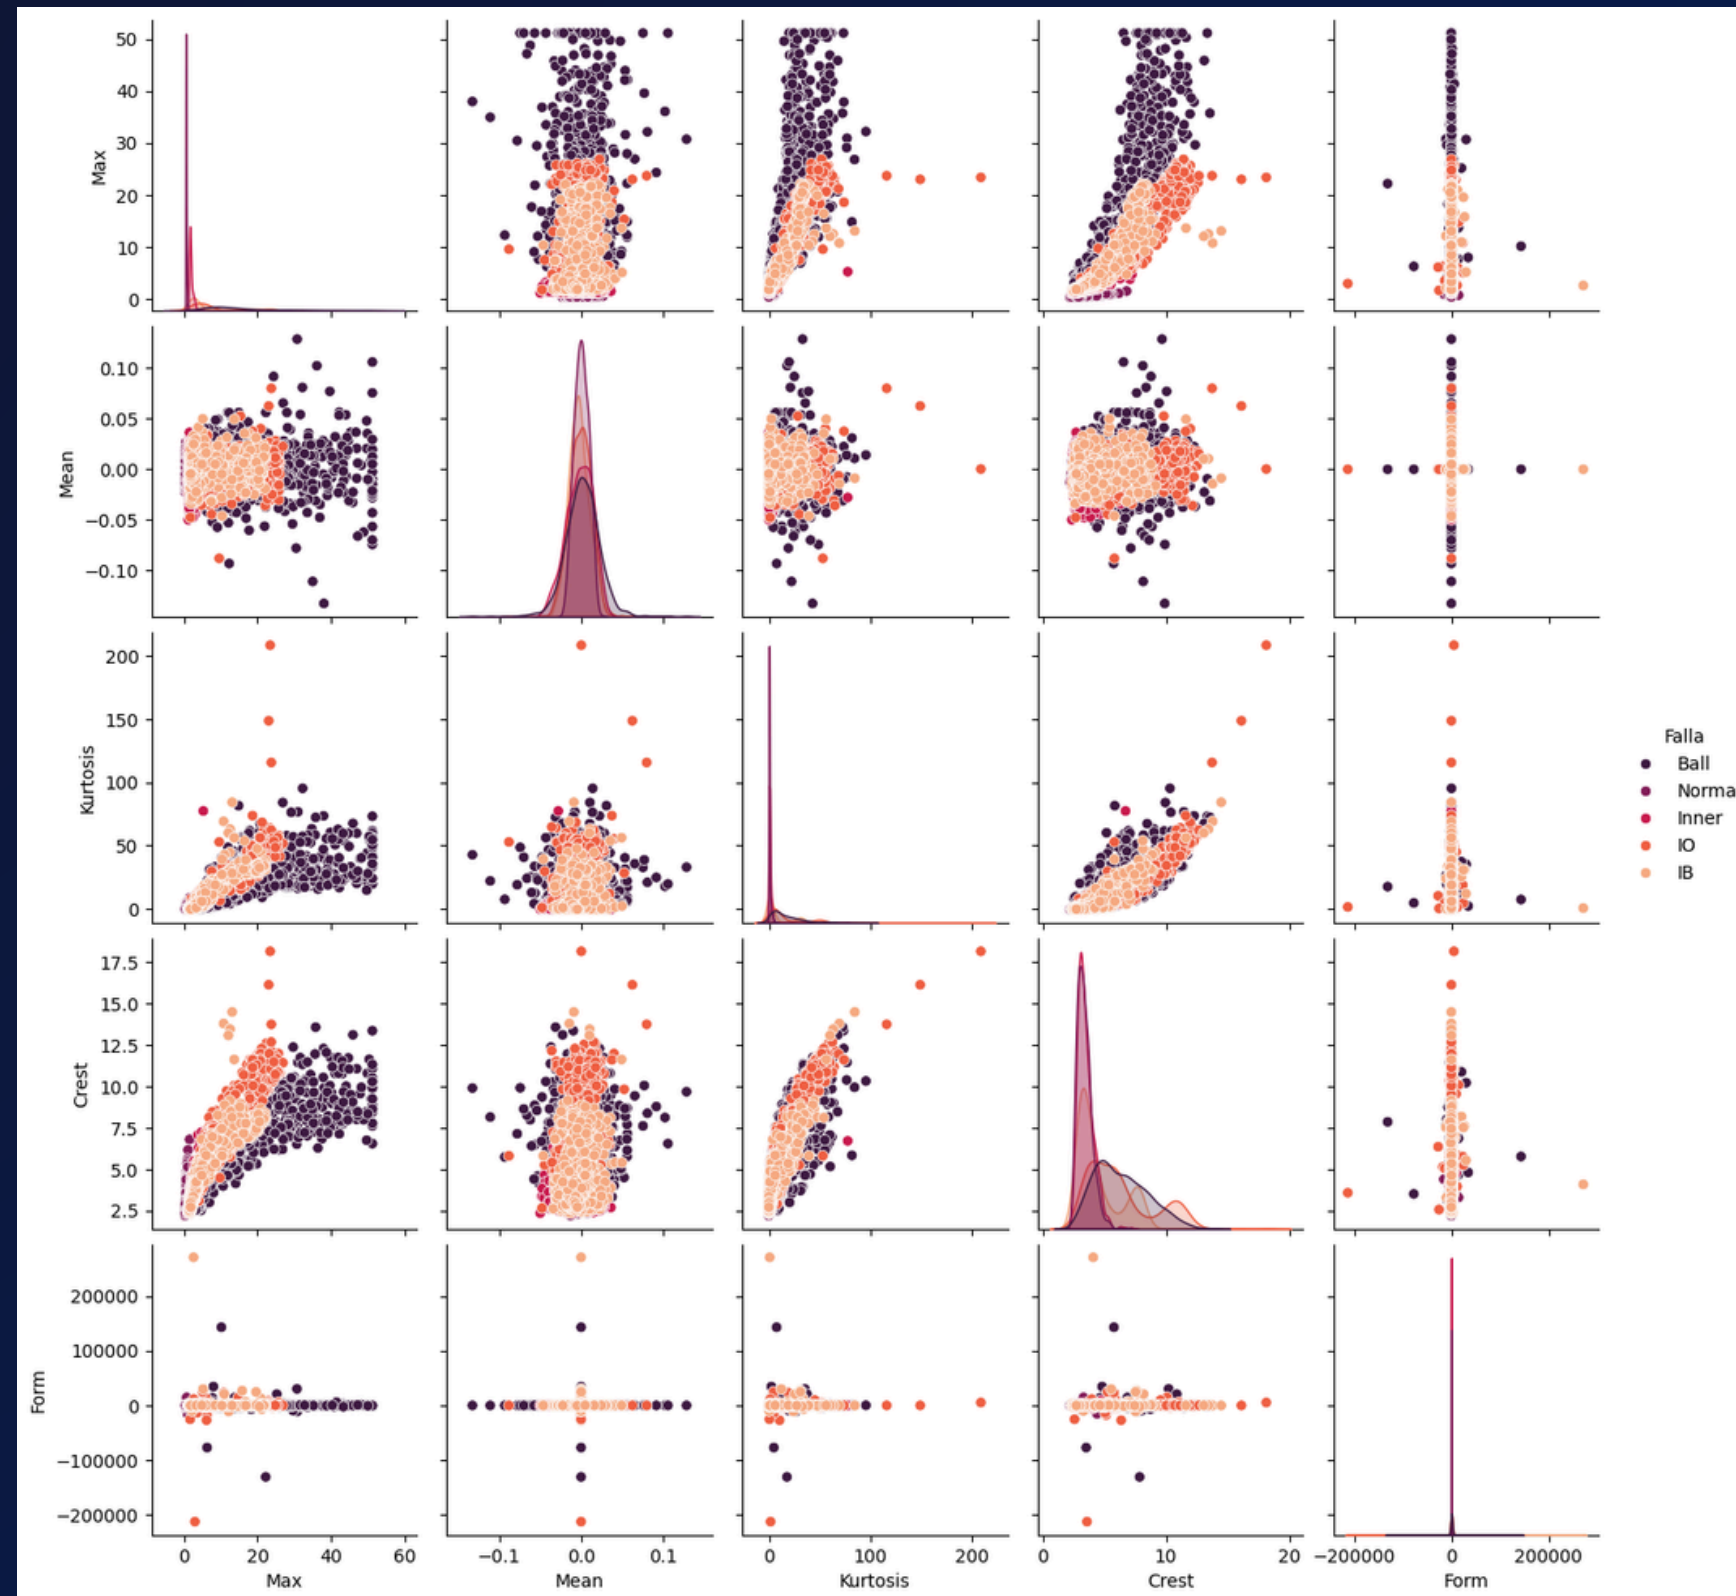
Cálculo de Características

Como se tienen 51200 datos por segundo con un total 10 segundos, a fin de tener una cantidad representativa de datos, se segmentaron en intervalos de 0,01 segundos. Nuestros datos dependen del tiempo entonces nos basamos en eso para poder elegir nuestros features

Se calculan las siguientes features:

- Valor máximo
 - Valor mínimo
 - Media
 - Desviación estándar
 - Valor cuadrático medio (RMS)
 - Asimetría (Skewness)
 - Curtosis
 - Factor de cresta (Crest factor)
 - Factor de forma (Form factor)
- 

Visualización y Análisis





Entrenamiento y prueba

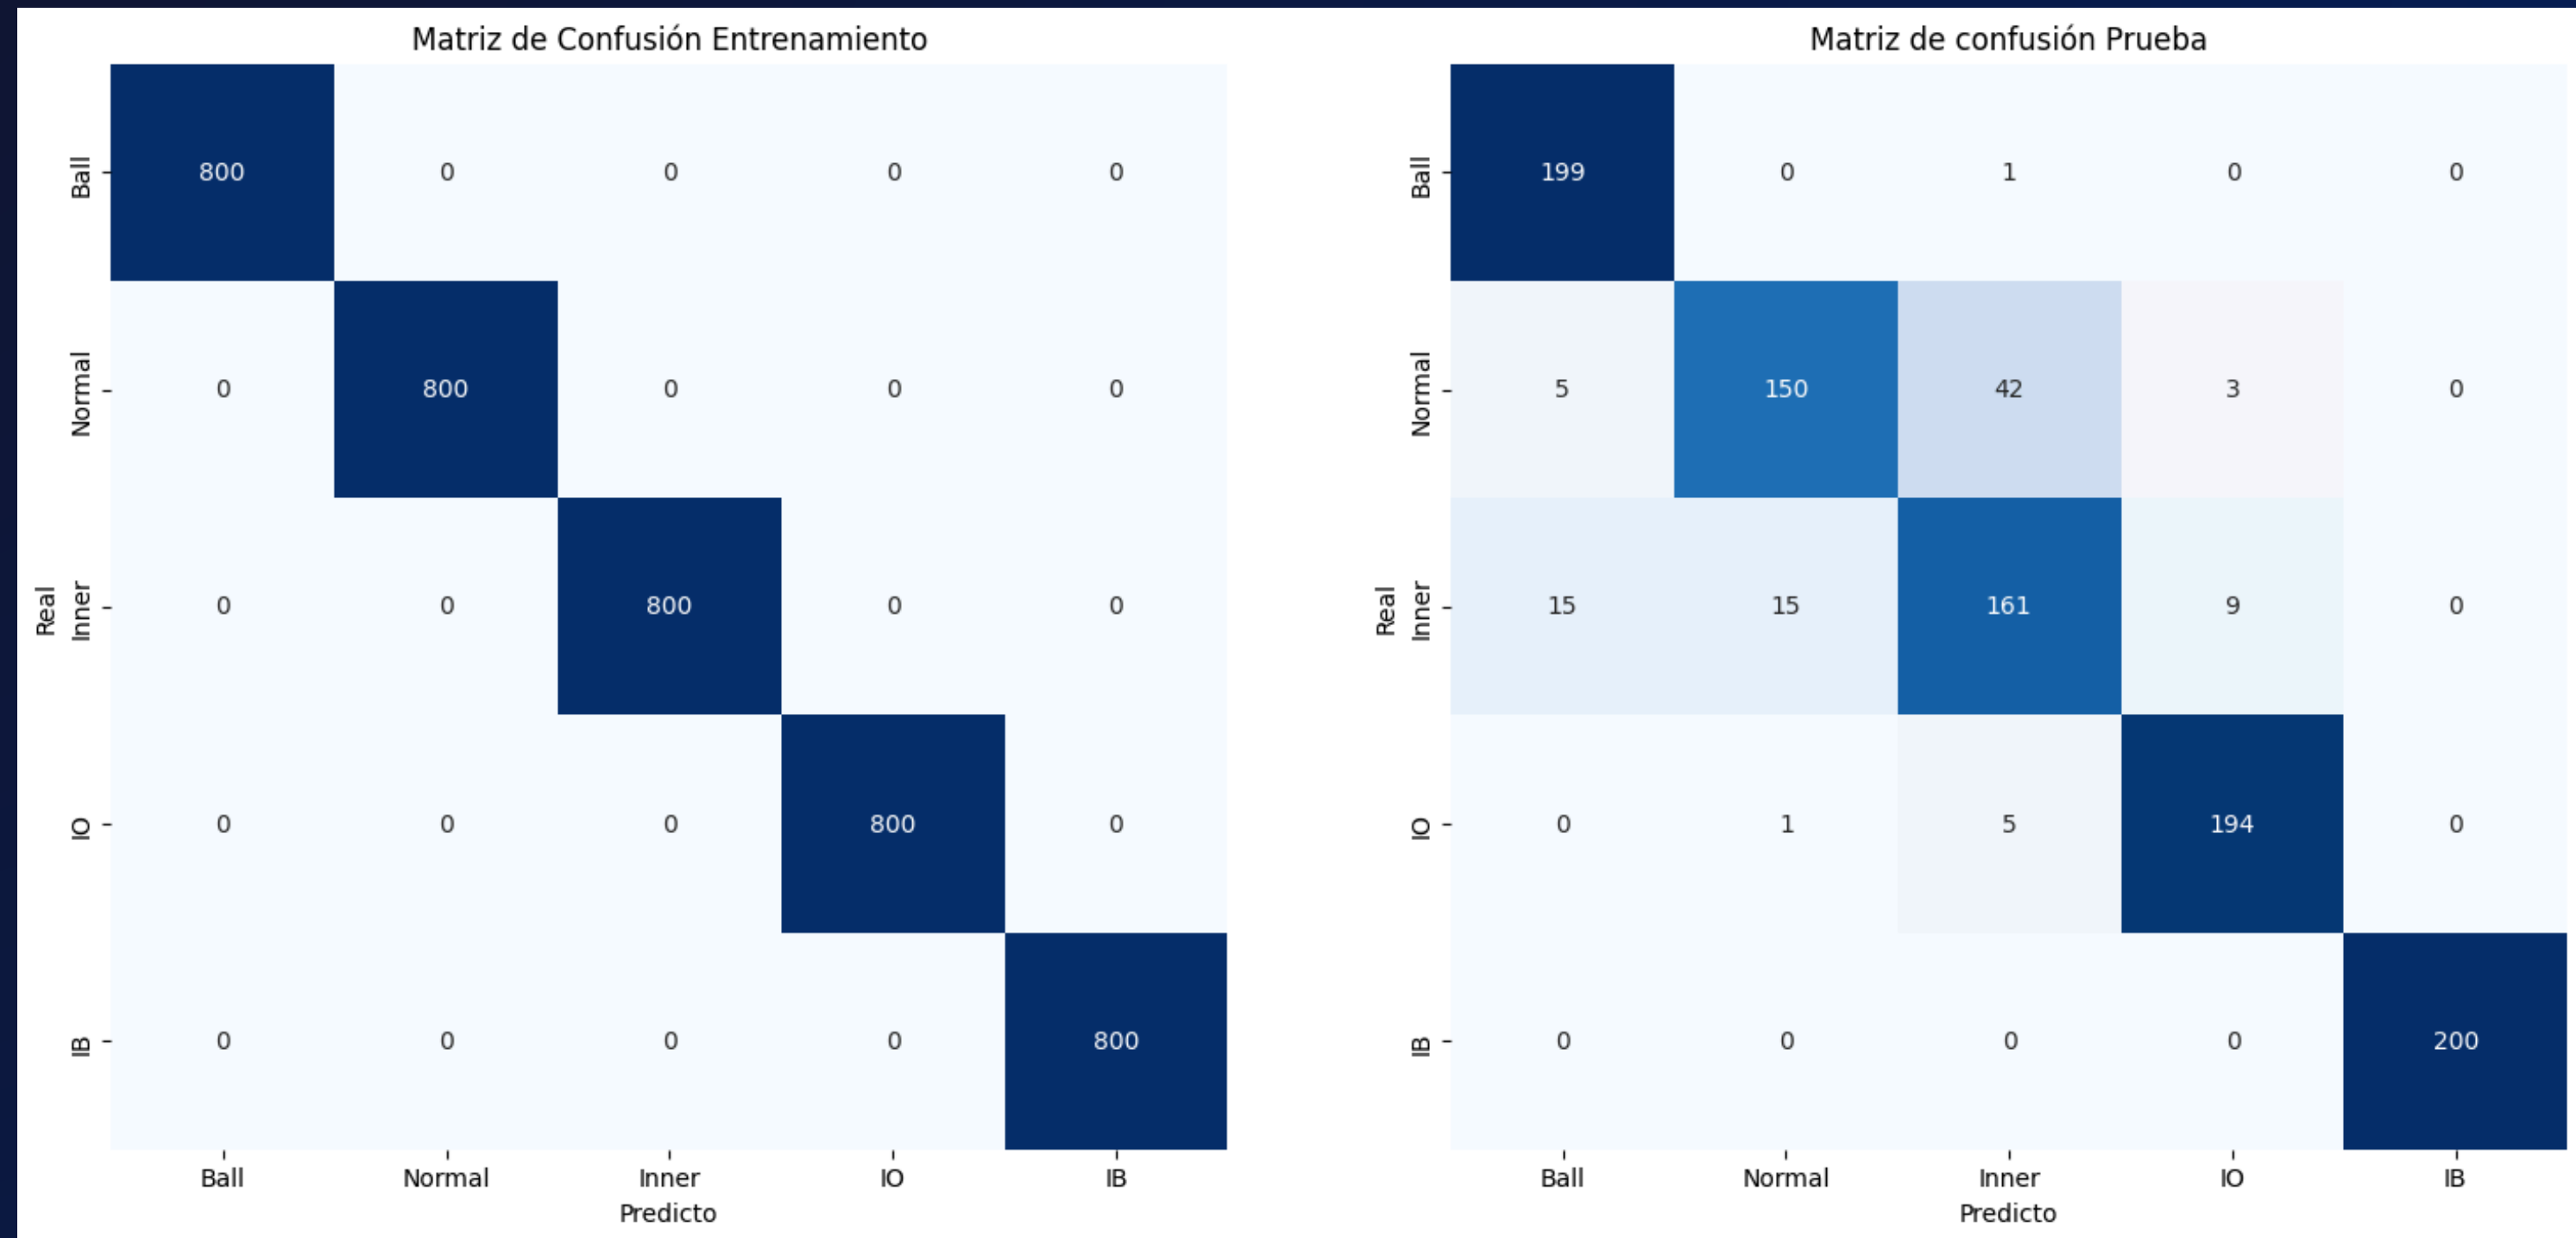
Se separaron los datos en datos de entrenamiento y de prueba, siendo el 80% para entrenamiento y el 20% para prueba.

Luego se procedió al escalado para posteriormente entrenar el modelo.

Los métodos utilizados fueron el de Random Forest Classifier y el SVM, obteniendo los siguientes resultados




Random Forest Classifier



Precisión en la prueba: 0.904

SVM



Precisión en la prueba: 0.896